Business Intelligence

Proyecto final · Entrega 1

Diagnóstico, estrategia y diseño

Hotelera Caribe S.A.S

Integrante	Código
Laura Sofia Franco Mateus	506241128
Karen Marcela Bayona Romero	506241093

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	*23/10/2026*
Repositorio	https://github.com/Karen-Bayona/bi-proyecto-equipo506241093

Resumen de la entrega

Hotelera Caribe S.A.S es una cadena hotelera ficticia, construida sobre datos públicos reales del turismo colombiano, con cinco hoteles en Cartagena de Indias (420 habitaciones). Su problema es que cada sede registra las reservas en formatos distintos, calcula la ocupación y la tarifa promedio con definiciones diferentes y conserva el histórico en archivos dispersos, mientras que un analista consolida los informes a mano en unos cinco días hábiles. Por eso el gerente general no tiene evidencia para fijar con 4 a 6 meses de antelación las tarifas por tipo de habitación ni la contratación de temporales, lo que causó en la última temporada de diciembre tarifas por debajo de lo posible y en Semana Santa sobre contratación de personal.

Según el modelo de madurez de BI (BIMM), la organización se encuentra en la fase 2 (datos accesibles sin BI), porque tiene los datos pero sin procesos formales ni definiciones comunes. El proyecto apunta a la fase 5 (crecimiento del DW y reporting formal), con un data warehouse en PostgreSQL, ETL en Pentaho PDI, un dashboard en Power BI y un modelo predictivo en Python, con la gobernanza de datos como capa transversal.

El modelo dimensional tiene una granularidad de una noche de una reserva confirmada de una habitación de un tipo determinado en un hotel de la cadena, en una fecha específica. Se organiza como un esquema en estrella: la tabla principal fact_reserva_noche más los hechos de capacidad diaria, llegadas de extranjeros (Migración Colombia) y mercado del destino (DANE), con dimensiones de tiempo, hotel, tipo de habitación, canal y nacionalidad.

1. Caso de negocio

1.1 Organización y contexto

Hotelera Caribe S.A.S es una cadena de hoteles ficticia construida sobre datos públicos reales del turismo colombiano. Las cifras internas que se mencionan son inventadas y se declaran como tales.

Hotelera Caribe S.A.S es una cadena hotelera mediana del sector turístico con sede en Cartagena de Indias. El hotel cuenta con 5 sedes dentro de Cartagena, ubicadas en diferentes partes. Tres de los hoteles se ubican en el centro histórico y Getsemaní, cuentan con 175 habitaciones en total, y dos hoteles de mayor tamaño en Bocagrande, con 245 habitaciones. En conjunto los 5 hoteles suman 420 habitaciones. En cuanto a los colaboradores de la empresa, cuentan con 180 empleados fijos, y en temporada alta contratan entre 40 y 80 temporales, así llegando a cerca de 260 personas. Cerca de un 33% de los visitantes son de otros países, mientras que los demás son turistas locales y personas que viajan por motivos laborales.

Actualmente cada hotel administra las reservas de manera individual. Los hoteles del centro usan un sistema de reservas que exporta las fechas como dd/mm/aaaa. Los de Bocagrande llevan sus registros en hojas de Excel con fechas mm-dd-aaaa. Ninguno de los hoteles conserva los registros en línea por más de doce meses, y los archivos que son de años anteriores se encuentran dispersos en los computadores de cada administrador de la sede. Además, cada sede aborda de manera distinta los indicadores, algunos calculan la ocupación sobre todas las habitaciones, y otros excluyen las que se encuentran en mantenimiento, también la tarifa promedio en ocasiones incluye impuestos y a veces no. Cada mes, un analista de la oficina administrativa recoge los cinco archivos, los une a mano en un libro de Excel y arma el informe de ocupación y tarifas. Esto le toma unos cinco días hábiles, de modo que el gerente recibe las cifras cuando el mes ya terminó y, en temporada alta, cuando la temporada ya empezó.

El gerente general, normalmente debe fijar las tarifas con cuatro a seis meses de antelación por tipo de habitación (estándar, superior y suite) y el plan de contratación temporal dependiendo de la temporada del año, ya sea diciembre, enero, Semana Santa, mitad de año o puentes festivos. Debe tomar esta decisión con antelación puesto que de ello dependen los ingresos que van a tener en el año y la nómina a la que la empresa se puede comprometer.

Hoy la empresa no puede tomar esas decisiones con evidencia, por tres razones. Primero, no sabe cuánta ocupación esperar en cada mes, porque no tiene un historial consolidado de años anteriores. Segundo, no considera de qué mercados llegarán los visitantes, aunque Migración Colombia publica los flujos de extranjeros por nacionalidad, ciudad de hospedaje y medio de transporte. Tercero, no puede comparar sus tarifas y su ocupación con las del destino, aunque el DANE publica cada mes los datos de Cartagena en su Encuesta Mensual de Alojamiento. Esta información pública se queda en tableros y archivos separados que nadie descarga ni cruza con los datos de la cadena. Además, cada entidad nombra la ciudad de forma distinta: Migración usa el nombre de la ciudad de hospedaje, el DANE su propia lista de ciudades y el Registro Nacional de Turismo códigos de municipio.

Como consecuencia de lo mencionado anteriormente, en la última temporada de diciembre, la cadena mantuvo las tarifas de la temporada anterior y agotó la disponibilidad de las habitaciones antes de lo previsto, de modo que pudo haber cobrado más por habitación. Otro error que ocurrió, fue que en temporada de Semana Santa se contrataron colaboradores de más pues no se tuvo la ocupación que el gerente pensó que iba a haber. Así generando pérdidas, pero que en el momento la empresa no se da cuenta, pues los datos llegan semanas después. De lo mencionado anteriormente, la empresa necesita un sistema de inteligencia de negocios que reúna en un solo lugar la información de sus cinco hoteles y los datos públicos del destino, con definiciones comunes de ocupación y tarifa, y que permita al gerente ver cuánta ocupación y qué tarifa conviene esperar por mes, antes de cada temporada.

1.2 Síntomas de arquitectura accidental

#	Síntoma	Evidencia en el caso	Capa afectada
S1	Cada hotel registra las reservas en formatos distintos	Los hoteles del Centro guardan la fecha como dd/mm/aaaa en el sistema de reservas, y los de Bocagrande exportan mm-dd-aaaa en Excel	Fuentes / Integración
S2	Los datos externos no se pueden cruzar con los internos	Migración Colombia usa el nombre de la ciudad de hospedaje, el DANE usa su propia lista de ciudades, y el RNT usa códigos de municipio. Nadie los unifica	Integración
S3	No hay un histórico consolidado	Cada sistema conserva solo 12 meses y los años anteriores están en archivos sueltos. No hay un almacén central	Almacén de datos
S4	Los informes se arman a mano	Cada mes, un analista une los cinco Excel de los hoteles y tarda unos cinco días hábiles. El gerente recibe el informe cuando ya empezó la temporada	Usuario final
S5	No hay definiciones comunes de los indicadores	Un hotel calcula ocupación sobre todas las habitaciones y otro excluye las que están en mantenimiento. La tarifa promedio unas veces incluye impuestos y otras no	Gobierno y metadatos

1.3 Preguntas de negocio

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
P0	¿Qué ocupación y qué tarifa promedio por tipo de habitación debe esperar Hotelera Caribe S.A.S en cada mes de los próximos 12 meses, para fijar tarifas y definir cuántos temporales contratar por temporada?	BA	Se busca predecir la ocupación y la tarifa en los meses futuros y a partir de esa proyección, se recomienda una decisión al gerente.
P1	¿Cómo han variado la ocupación y la tarifa promedio de la cadena por mes y por tipo de habitación en los últimos años?	BI	Se quiere describir lo ocurrido en años anteriores, con datos históricos que estén estructurados, y presentados en tablas y gráficos.
P2	¿Cuántos visitantes extranjeros se esperan en Cartagena en los próximos meses, por nacionalidad?	BA	Se pide pronosticar la llegada futura a partir de datos de años anteriores y la regularidad de los visitantes.
P3	¿Qué temporadas dejan más ingresos por habitación disponible en cada tipo de habitación?	BI	Se describen los ingresos pasados por temporadas y el tipo de habitación con datos anteriores de la empresa que estén estructurados.
P4	¿Cuántas habitaciones de cada hotel estarán ocupadas en cada semana de temporada alta, para asignar el personal de recepción y limpieza?	BA	Se quiere pronosticar la ocupación semanal futura para así asignar personal a las necesidades de los huéspedes.

2. Inventario de fuentes

2.1 Fuentes

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
F1. Flujos migratorios de extranjeros: tableros 2023, 2024 y 2025, Migración Colombia	https://www.migracioncolombia.gov.co/planeacion-y-estadistica/observatorio-om3/datos-abiertos/tableros-de-visualizacion	CSV	1.639 filas (suma de nueve archivos CSV: tres por año)	Ene 2023 – dic 2025	21 Oct 2026	Información pública del Estado colombiano – Libre consulta y uso académico (Datos Abiertos)
F2. Encuesta Mensual de Alojamiento (EMA), DANE	https://www.dane.gov.co/index.php/estadisticas-por-tema/servicios/encuesta-mensual-de-alojamiento-ema	Excel (.xlsx)	36 registros mensuales	Ene 2023 – dic 2025	21 Oct 2026	Información pública del Estado colombiano (DANE) – Libre consulta y uso académico
F3. Reservas de Hotelera Caribe S.A.S. (**sintética**)	Generada por el equipo con un script propio, en datos/ del repositorio https://github.com/Karen-Bayona/bi-proyecto-equipo506241093	CSV	121.893 registros	Ene 2023 – dic 2025	22 Oct 2026	Uso académico; datos ficticios sin personas reales

2.2 Problemas de calidad detectados

Fuente	Campo	Problema	Ejemplo real del dato
F1	Total (tableros)	Número guardado como texto, con separador de miles distinto entre años	2023: 481,626. 2025: 619.405
F1	Ciudad de hospedaje	Solo nombre, sin código de municipio. Hay nombres parecidos y comas dentro del nombre	Cartagena de Indias (619.405) y Cartagena del Chairá (494), además de Bogotá, D.C.
F1	Comportamiento mensual	Diseño ancho con dos filas de encabezado y filas de porcentaje entre los datos	Cada mes aparece dos veces (Enero, Enero) con las columnas Entradas y Salidas
F1	País de nacionalidad	Nombres oficiales largos y una columna auxiliar de Tableau	Venezuela (República Bolivariana de); columna Color país nacionalidad con valores como Menos de 1.000
F2	Año	El año solo está en la primera fila de cada año	Hoja 4.2: 2024 en enero; de febrero a diciembre, la celda está vacía

Fuente	Campo	Problema	Ejemplo real del dato
F2	Notas al pie	Texto explicativo mezclado con los datos, después del último mes	Filas Fuente: DANE, EMA, p: Cifra provisional y Actualizado el 13 de febrero de 2026
F2	Encabezados de región	Espacios sobrantes y saltos de línea en los nombres	'Caribe ', ' Eje Cafetero', 'Golfo de Morrosquillo \ny Sabana'
F2	Unidades entre hojas	Cada hoja usa otra unidad y otro periodo	Ocupación en % (0–100); tarifas como índice base 2019=100; ingresos como variación desde 2020
F3	Fecha de reserva	Formato de fecha distinto según la zona del hotel	RES-000001 (H1, Centro): 01/01/2023; RES-013830 (H4, Bocagrande): 04-28-2023
F3	Identificador de reserva	Identificadores duplicados	RES-000087 aparece dos veces, idéntica (H4, 01-01-2023, tarifa 504.000). En total, 1.801 filas repetidas
F3	Canal de venta y nacionalidad	Valores nulos	RES-000004 (H1) sin canal, con nacionalidad Brasil. Nulos en canal: 4.804
F3	Tarifa y tipo de habitación	Tarifa con IVA en unos hoteles y sin IVA en otros, sin columna que lo indique	Promedio de H1 (Centro): 454.399; de H4 (Bocagrande, con IVA): 407.334. No son comparables

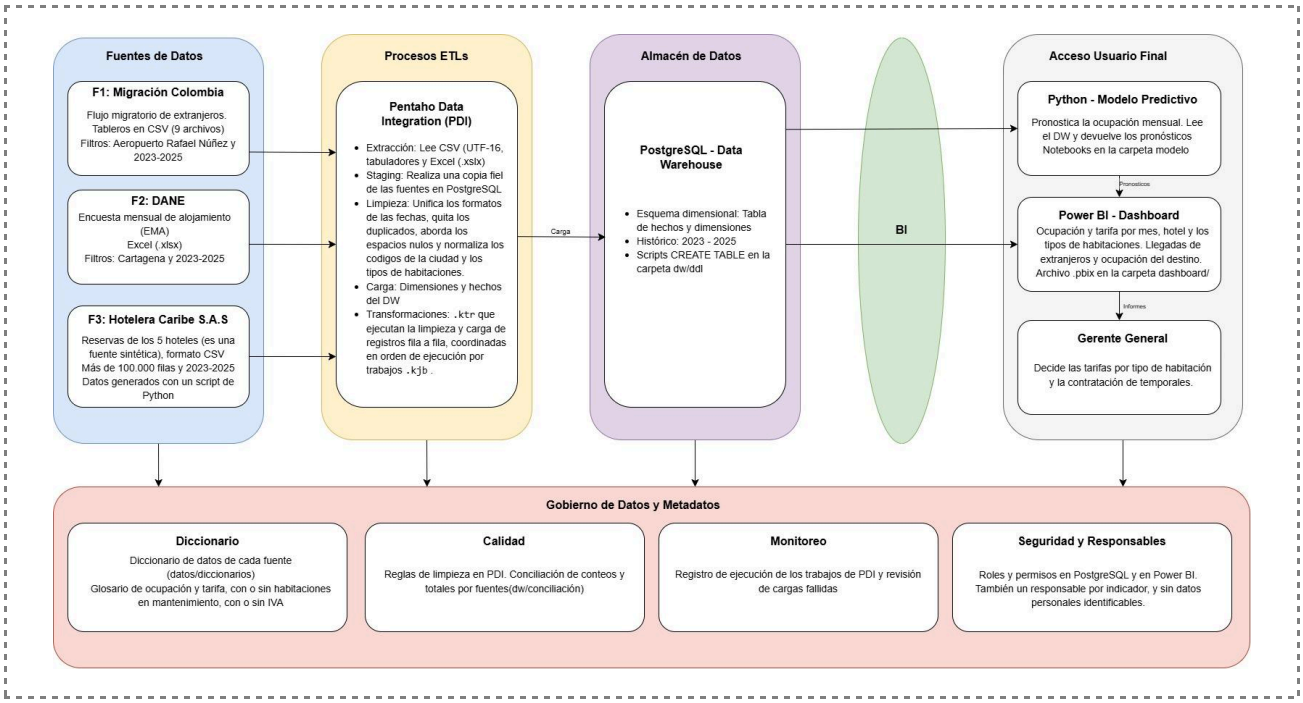
3. Diagnóstico de madurez

Elemento	Respuesta
Fase actual	Fase 2: Datos accesibles sin BI.
Evidencia	Los datos en este momento existen y son accesibles, sin embargo no cuentan con un tratamiento o un procedimiento formal, pues como se puede observar en S1 cada sede del hotel realiza las reservas con formatos distintos, también en S3 los archivos históricos están dispersos en varios computadores sin ser consolidados. Igualmente el reporte se realiza de manera manual y en Excel, identificado como S4 se menciona que un analista es el encargado de unificar los 5 archivos cada mes y tarda cinco días hábiles. Y por último, los síntomas S2 y S5 muestran cómo las diferentes sedes manejan distintos indicadores confirmándose que no hay un tratamiento de los datos.
Por qué no es la fase siguiente	La fase 3 obliga a tener procesos formales de decisión basados en datos y un equipo que realice el tratamiento de datos. Sin embargo, en el hotel solo una persona es el encargado de analizar los datos a mano, en donde no hay definiciones comunes, el informe no llega en el tiempo que se requiere y el gerente general toma de decisiones por intuición. Es decir, esta cadena hotelera no cuenta con un responsable de los datos, definiciones únicas, y toma de decisiones apoyadas en datos.
Fase objetivo al final del proyecto	El objetivo es culminar con la fase 5, en donde se observe un crecimiento del DW y reporting formal. El proyecto busca entregar un almacén de datos funcionando y un reporte corporativo único. No llega a la fase 6 porque no despliega OLAP ni cambia la cultura de decisión de toda la organización.

Elemento	Respuesta
Brechas que cierra el proyecto	★ **B1.** Datos en formatos y códigos distintos (S1, S2) → *Integración:* Pentaho PDI (transformaciones que unifican fechas, ciudades y tipos de habitación). ★ **B2.** Sin histórico consolidado (S3) → *Almacén:* DW con esquema dimensional y carga histórica 2023–2025. ★ **B3.** Informes manuales y tardíos (S4) → *Usuario final:* dashboard en Power BI sobre el DW. ★ **B4.** Indicadores sin definición común (S5) → *Gobierno y metadatos:* glosario de ocupación y tarifa, diccionario de datos y un responsable por indicador. ★ **B5.** Datos públicos sin uso → *Fuentes e integración:* F1 y F2 cargadas al DW junto a las reservas.

4. Arquitectura

4.1 Diagrama de cinco capas del caso



4.2 Componentes por capa

Capa	Componentes y herramientas del caso	Función en el caso
1. Fuentes de datos	★ F1: Migración Colombia, tableros de flujo migratorio de extranjeros (9 archivos CSV, 1.639 filas, 2023-2025). ★ F2: DANE, Encuesta Mensual de Alojamiento (Excel .xlsx, 36 registros mensuales de Cartagena). ★ F3: reservas de Hotelera Caribe S.A.S (CSV sintético, 121.893 registros, generado con un script de Python).	Aportan las reservas de las diferentes sedes del hotel y la llegada de extranjeros por nacionalidad y ocupación y tarifas de Cartagena. Sin ellas no se puede responder P0 a P4.

Capa	Componentes y herramientas del caso	Función en el caso
2. Integración (ETL)	Pentaho Data Integration (PDI): transformaciones .ktr coordinadas por trabajos .kjb. Se basa en la organización de todo el proceso: lee los archivos de origen, guarda una copia temporal en la base de datos, limpia los errores y deja la información lista.	Extrae las tres fuentes y deja una copia fiel en staging. Unifica los formatos de fecha, quita los datos duplicados, trata los datos nulos, normaliza las ciudades, los tipos de habitación y homologa el IVA. Luego carga dimensiones y hechos al DW. Cierra las brechas B1 y B5.
3. Almacén de datos	Una base de datos centralizada en PostgreSQL que organiza la información histórica (2023–2025) en tablas de hechos y dimensiones, creada mediante scripts en dw/ddl.	Centraliza el histórico consolidado que hoy está disperso en los computadores de cada sede, con una sola definición de ocupación y tarifa. Es la única fuente para el dashboard y el modelo predictivo. Cierra la brecha B2.
4. Usuario final	★ Modelo predictivo en Python: Lee los datos procesados y pronostica cuánta ocupación habrá cada mes. ★ Tablero en Power BI: Muestra gráficos interactivos con tarifas, ocupación por hotel o habitación y llegada de turistas. ★ Gerente General: Usuario principal que revisa los reportes para tomar decisiones del negocio.	Python responde los pronósticos y Power BI responde el histórico, reemplazando el informe manual de cinco días. El gerente usa ambos informes para fijar tarifas por tipo de habitación y decidir la contratación de temporales antes de cada temporada.
5. Gobierno, metadatos, monitoreo y seguridad	★ Diccionario de datos: Explica qué significa cada campo y columna de las fuentes. ★ Calidad de datos: Aplica reglas para limpiar, validar y verificar que las cifras sean exactas. ★ Monitoreo: Registra el historial de ejecuciones en Pentaho y alerta si alguna carga falla. ★ Seguridad y responsables: Controla los permisos en PostgreSQL y Power BI, asigna un responsable por indicador y protege la privacidad.	Capa transversal que define el significado de los datos, asegura su calidad, rastrea los procesos de carga y controla los permisos de acceso para solucionar la brecha.

4.3 Marco de Referencia de cuatro categorías

Categoría	Decisión tomada	Justificación
Arquitectura de información	Establecer la información clave del Gerente General mediante dos indicadores: ocupación (habitaciones ocupadas/ disponibles, sin contar mantenimiento) y tarifa promedio (sin IVA). Se analizan por mes, el hotel y el tipo de habitación, cruzando las reservas de la cadena con la llegada de extranjeros y el mercado de	Actualmente las sedes calculan la ocupación y tarifas de forma diferente, impidiendo comparar sus cifras. Como el Gerente General fija precios y contrata personal con cuatro a seis meses de anticipación, requiere datos confiables por temporada y habitación. Estandarizar estas reglas antes del desarrollo evita construir modelos sobre información errónea.

Categoría	Decisión tomada	Justificación
	Cartagena. Cada indicador tiene un responsable asignado.	
Arquitectura de datos	Definir un Data Warehouse en PostgreSQL estructurado en tablas de hechos y dimensiones con histórico 2023–2025. Incluyendo una zona intermedia que copie fielmente los archivos originales para limpiar y normalizar fechas y códigos de ciudad. Sus dimensiones compartidas permiten integrar las fuentes bajo una misma estructura.	El modelo dimensional facilita las consultas por mes, hotel y tipo de habitación, sirviendo de base para los reportes y los pronósticos. La zona intermediaria garantiza la trazabilidad y la reejecución de cargas, mientras que las dimensiones unificadas resuelven la falta de nombres de ciudad estandarizados, las inconsistencias en fechas y la ausencia de un histórico consolidado.
Arquitectura técnica	Definir el stack tecnológico del proyecto. Primero, Pentaho extrae, limpia y carga los datos mediante archivos .ktr coordinados por .kjb, luego de ello PostgreSQL actúa como Data Warehouse central. Python ejecuta los modelos predictivos y Power BI genera el dashboard interactivo. Por último, GitHub asegura el versionado de scripts, estructuras DDL, transformaciones y diagramas.	Seleccionar herramientas gratuitas y conocidas por el equipo: Pentaho maneja visualmente archivos CSV y Excel documentando su limpieza, PostgreSQL soporta con holgura más de 120 mil registros conectándose con Python y Power BI, Python resuelve la parte predictiva avanzada y GitHub garantiza el versionado y la trazabilidad del trabajo en equipo.
Arquitectura de producto	Se definen dos productos clave para el Gerente General: un dashboard en Power BI que muestra ocupación, tarifas, llegada de extranjeros y comparación con el destino, y un modelo predictivo en Python que pronostica la ocupación mensual e integra sus resultados en el mismo tablero. Ambos productos se actualizan de forma automática con cada carga del Data Warehouse y no de manera manual.	Garantizar herramientas alineadas con las decisiones del Gerente General, como son fijar las tarifas por habitación y contratar personal antes de cada temporada. El dashboard automatizado elimina el informe manual, mientras que el pronóstico responde a las preguntas predictivas. Integrar ambos productos en un solo tablero evita al usuario alternar entre distintas aplicaciones.

4.4 Decisión de despliegue

Criterio	On-premise	Opción cloud: PaaS	Elegida y por qué
Costo	Exige comprar y mantener hardware, respaldos y energía, además de personal especializado en sistemas y bases de datos. Sin embargo, la cadena carece de un área de TI de datos, contando únicamente con un analista en la oficina administrativa.	Se evita la inversión inicial en hardware al operar bajo un modelo de pago por uso, donde el proveedor administra el sistema operativo, las actualizaciones y los respaldos. Dado que el volumen es pequeño, el costo operativo mensual sería bajo.	Al elegir un modelo Cloud (PaaS), se evita una inversión en infraestructura que no se justifica para el volumen de datos del proyecto. Además, minimiza las tareas de administración de sistemas y mantenimiento, ajustándose perfectamente a la capacidad actual del equipo de la cadena.
Seguridad y cumplimiento	La cadena de hoteles mantiene el control de los datos, pero asume la responsabilidad operativa de respaldos, seguridad y mantenimiento.	Delegar la infraestructura al proveedor asegura cifrado, respaldos automáticos y alta disponibilidad, mientras	Cloud (PaaS) garantiza altos estándares de seguridad y continuidad inaccesibles para la cadena. Al no almacenar datos personales identificables de

Criterio	On-premise	Opción cloud: PaaS	Elegida y por qué
	Ubicar la base de datos localmente o en un equipo personal prolonga el problema actual de información fragmentada y sin respaldo centralizado.	que la cadena gestiona el acceso y la privacidad de los datos.	huéspedes, reduce el riesgo de incumplimiento normativo, gestionando los accesos mediante roles en PostgreSQL y Power BI.
Escalabilidad	La escalabilidad en un entorno local implica anticipar el crecimiento y adquirir hardware adicional con anticipación. Si la cadena incorpora nuevas sedes o consolida más años de histórico, será necesario realizar inversiones para ampliar la capacidad física del servidor.	Permite escalar cómputo y almacenamiento bajo demanda de forma inmediata, facilitando aumentar la capacidad durante procesos intensivos de carga o ante la incorporación de nuevos hoteles, y reduciéndose cuando no sea necesaria para optimizar costos.	Cloud (PaaS) permite absorber el crecimiento mensual de reservas y datos públicos de forma continua. Ante la posible incorporación de nuevas sedes a la cadena, escalar la capacidad bajo demanda resulta infinitamente más rápido y sencillo que adquirir o potenciar un servidor propio.
Acceso móvil	El acceso desde fuera de la oficina requiere VPN o abrir el servidor a internet, lo que es complejo y riesgoso para los gerentes.	Power BI Service publica el dashboard en la web y en la aplicación móvil, con acceso desde cualquier lugar con control de usuarios.	Cloud (SaaS en la capa de usuario). El gerente general puede consultar tarifas y ocupación desde el celular al decidir tarifas o la contratación de temporales, sin depender de estar en la oficina.

5. Modelo dimensional

5.1 Proceso de negocio

El proceso de negocios que se realiza en Hotelera Caribe S.A.S se aborda desde el modelaje de la tabla de hechos que son las reservas de alojamientos, desde que un huésped realiza el proceso de reserva hasta que ya se encuentra en la habitación. Este proceso genera los ingresos de la cadena y alimenta los dos indicadores con los que el gerente general puede tomar decisiones.

En cada uno de los hoteles el huésped puede reservar una habitación con la que se sienta cómoda, pudiendo elegir entre las tres opciones con las que se cuentan, ya sea por una noche o varias noches, realizándose por un canal de venta y una tarifa. A partir de ello, cada reserva queda registrada con la fecha, el hotel, el tipo de habitación, el canal de venta, la nacionalidad del huésped y la tarifa pactada. En la actualidad ese proceso se está realizando de manera distinta en cada uno de los hoteles y por eso el proceso se realiza en el almacén de datos con una sola estructura y un diccionario en común.

Se elige este proceso de negocio puesto que responde satisfactoriamente a las necesidades del gerente para la toma de decisiones, pues va a responder cuánta ocupación y qué tarifa espera por habitación y por mes, permitiendo fijar tarifas y definir el personal necesario en temporadas altas. Igualmente, con el histórico de 2023 - 2025 puede responder las preguntas descriptivas y alimentar el pronóstico de ocupación y tarifa. Finalmente, los datos públicos de Migración Colombia y del DANE no son parte del proceso de reservas, pues se incorporan como información de contexto del destino para comparar la cadena con el mercado y mejorar el pronóstico.

5.2 Granularidad

Una fila de la tabla de hechos representa una noche de una reserva confirmada de una habitación de un tipo determinado en un hotel de Hotelera Caribe S.A.S., en una fecha específica.

Nota: Se eligió el nivel de noche y no el de reserva porque muchas estancias cruzan de un mes a otro, y con una fila por reserva esas noches quedarían asignadas a un solo mes. Con una fila por noche, la ocupación y la tarifa promedio se calculan correctamente por día, semana, mes, hotel y tipo de habitación.

5.3 Métricas de la tabla de hechos

Métrica	Tipo de dato	Aditividad	Origen o fórmula
noches_ocupadas	Entero	Aditiva	Vale 1 por cada noche de ocupación. Se calcula expandiendo el rango entre fecha_entrada y fecha_salida de F3, con un registro diario por habitación. Solo se cuentan las reservas con estado Confirmada.
tarifa_noche_sin_iva	Decimal (COP)	No aditiva	A los hoteles H4 y H5 (Bocagrande) se les divide la tarifa entre 1,19 para retirar el IVA y unificarla con el criterio neto de H1, H2 y H3. Para promediarla se usa ingreso_habitaciones / noches_ocupadas.
ingreso_habitaciones	Decimal (COP)	Aditiva	Equivale a la tarifa_noche_sin_iva de cada registro, porque la tabla desglosa la reserva a una fila por noche.
numero_huespedes	Entero	Semiaditiva	Se suma entre hoteles o habitaciones en un mismo día, pero no a lo largo del tiempo, porque duplicaría a los huéspedes que se quedan varias noches.

5.3.1 Métricas de otras tablas de hechos

Además de fact_reserva_noche, el modelo incluye tres tablas de hechos con otra granularidad. Comparten las dimensiones de tiempo, hotel, tipo de habitación y nacionalidad, y por eso pueden combinarse con las reservas. Sus métricas se documentan por separado.

Resumen de las tablas de hechos complementarias

Tabla de hechos	Granularidad	Dimensiones	Fuente
fact_capacidad_diaria	Una fila por día, hotel y tipo de habitación	dim_tiempo, dim_hotel, dim_tipoHabitacion	Inventario de habitaciones de la cadena (datos de capacidad)
fact_llegadas_extranjeros	Una fila por mes y nacionalidad	dim_tiempo, dim_nacionalidad	F1. Migración Colombia
fact_mercado_destino	Una fila por mes (Cartagena)	dim_tiempo	F2. EMA

Métricas de fact_capacidad_diaria

Métrica	Tipo de dato	Aditividad	Origen o fórmula
habitaciones_disponibles	Entero	Semiaditiva	Inventario fijo de habitaciones por hotel y tipo, sin contar las que están en mantenimiento. Se suma entre hoteles y tipos de habitación en un mismo día, pero no a lo largo del tiempo, porque representa capacidad instalada y no un flujo acumulable.

Métricas de fact_llegadas_extranjeros

Métrica	Tipo de dato	Aditividad	Origen o fórmula
total_llegadas	Entero	Aditiva	Total de extranjeros por nacionalidad y mes, filtrado a Cartagena de Indias en F1. Se convierte de texto a entero, unificando el separador de miles (481,626 y 619.405). Se puede sumar entre nacionalidades y entre meses.

Métricas de fact_mercado_destino

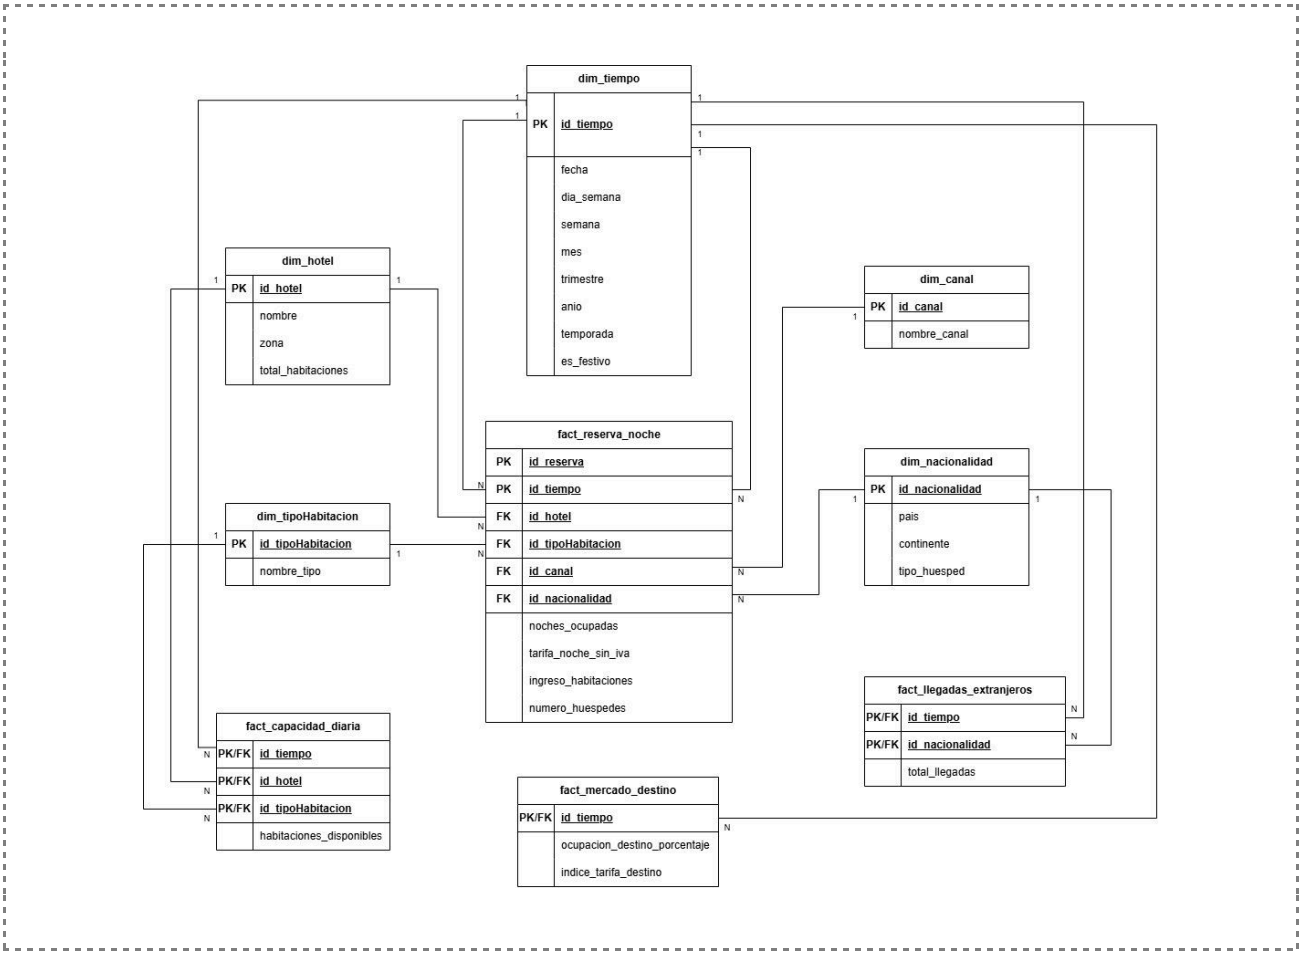
Métrica	Tipo de dato	Aditividad	Origen o fórmula
ocupacion_destino_porcentaje	Decimal (%)	No aditiva	Ocupación mensual de Cartagena en la hoja 4.2 de F2, en escala de 0 a 100. Se redondea y los valores “-” se tratan como nulos. No se suma: se promedia o se compara.
indice_tarifa_destino	Decimal (índice)	No aditiva	Índice de tarifa de Cartagena en la hoja 6.1 de F2, con base 2019 = 100. No está en pesos, por lo que no se compara directamente con la tarifa de F3. Sirve para ver la tendencia del destino.

5.4 Dimensiones

Dimensión	Atributos principales	Jerarquía	Fuente
Tiempo	fecha, día de la semana, semana, mes, trimestre, año, temporada e indicador de festivo	día → mes → trimestre → año *(la semana y la temporada se usan como agrupaciones adicionales)*	Generada
Hotel	id_hotel (H1 a H5), nombre, zona (Centro Histórico, Getsemaní, Bocagrande), total de habitaciones	hotel → zona → cadena	F3 y datos de capacidad
Tipo de habitación	id_tipoHabitacion, nombre normalizado (Estándar, Superior, Suite)	Sin jerarquía	F3 normalizada

Dimensión	Atributos principales	Jerarquía	Fuente
Canal de venta	id_canal, nombre	Sin jerarquía	F3
Nacionalidad	id_nacionalidad, país (nombre homologado), continente, tipo de huésped (nacional o extranjero)	país → continente	F3 y F1

5.5 Diagrama del esquema



Se eligió un esquema en estrella porque las dimensiones del negocio son pequeñas y estables, por lo que desglosarlas más solo complicaría las consultas en Power BI. Esto permite unir la tabla principal de reservas directamente con las dimensiones, facilitando el cálculo de la ocupación y tarifas, y haciendo el modelo mucho más intuitivo para el gerente. Las jerarquías se manejan dentro de cada misma tabla, mientras que los datos externos y la capacidad se organizan en tablas de hechos independientes que comparten las mismas dimensiones, logrando un esquema claro y sin duplicar información.

5.6 Trazabilidad con las preguntas

Pregunta	Métricas que usa	Dimensiones que usa
P0. Ocupación y tarifa promedio por tipo de habitación esperadas en cada mes de los próximos 12 meses	★ Internas: noches_ocupadas e ingreso_habitaciones (fact_reserva_noche); habitaciones_disponibles (fact_capacidad_diaria). ★ Externas: total_llegadas (fact_llegadas_extranjeros); ocupacion_destino_porcentaje e indice_tarifa_destino (fact_mercado_destino).	dim_tiempo (mes, anio, temporada, es_festivo), dim_tipoHabitacion, dim_hotel, dim_nacionalidad
P1. Variación de la ocupación y la tarifa promedio por mes y tipo de habitación en los últimos años	★ Métricas solamente internas: noches_ocupadas, tarifa_noche_sin_iva e ingreso_habitaciones (fact_reserva_noche); habitaciones_disponibles (fact_capacidad_diaria). Ocupación = noches_ocupadas / habitaciones_disponibles. Tarifa promedio = ingreso_habitaciones / noches_ocupadas.	dim_tiempo (mes, trimestre, anio), dim_tipoHabitacion, dim_hotel
P2. Visitantes extranjeros esperados en Cartagena en los próximos meses, por nacionalidad	★ Métrica externa: total_llegadas (fact_llegadas_extranjeros)	dim_tiempo (mes, anio, temporada), dim_nacionalidad (pais, continente)
P3. Temporadas que dejan más ingresos por habitación disponible en cada tipo de habitación	★ Métricas solamente internas: ingreso_habitaciones (fact_reserva_noche); habitaciones_disponibles (fact_capacidad_diaria). Indicador = ingreso_habitaciones / habitaciones_disponibles.	dim_tiempo (temporada, anio), dim_tipoHabitacion, dim_hotel
P4. Habitaciones ocupadas de cada hotel por semana de temporada alta, para asignar personal de recepción y limpieza	★ Métricas solamente internas: noches_ocupadas (fact_reserva_noche); habitaciones_disponibles (fact_capacidad_diaria)	dim_tiempo (semana, temporada, es_festivo), dim_hotel

Nota: Los indicadores que combinan métricas de fact_reserva_noche y fact_capacidad_diaria se calculan con las dimensiones compartidas (tiempo, hotel y tipo de habitación). Las tablas de hechos externas se asocian a dim_tiempo en granularidad mensual.

6. Referencias

Anthropic. (2025). Claude (Versión 5.5) [Large language model]. https://claude.ai/
DANE. (s. f.). *Encuesta Mensual de Alojamiento (EMA)*. Departamento Administrativo Nacional de Estadística. Recuperado el 21 de octubre de 2026. https://www.dane.gov.co/index.php/estadisticas-por-tema/servicios/encuesta-mensual-de-alojamiento-ema
Draw.io - free flowchart maker and diagrams online. (n.d.). https://draw.io/
Migración Colombia. (n.d.). *Tableros estadísticos - Migración Colombia*. https://www.migracioncolombia.gov.co/planeacion-y-estadistica/observatorio-om3/datos-abiertos/tableros-de-visualizacion
Pájaro Fuentes, L. (2026). *Arquitectura de un Sistema de BI: Decisiones de Diseño y Componentes* [Diapositivas de clase]. Facultad de Matemáticas e Ingenierías, Fundación Universitaria Konrad Lorenz.
Pájaro Fuentes, L. (2026). *Estrategia y Madurez de Negocio: Introducción y Conceptos Básicos* [Diapositivas de clase]. Facultad de Matemáticas e Ingenierías, Fundación Universitaria Konrad Lorenz.
Salas-Zárate, M., & Colombo-Mendoza, L. (2012). *CLOUD COMPUTING: A REVIEW OF PAAS, IAAS, SAAS SERVICES AND PROVIDERS*. Redalyc.org. https://www.redalyc.org/articulo.oa?id=613965334010

Anexos

Anexo A. Diccionarios de datos

Anexo A.1. Diccionario F3: Reservas de Hotelera Caribe S.A.S. (CSV, 121.893 registros)

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
id_reserva	Texto	Identificador único de la reserva	RES-000001	1.801 filas repetidas (120.092 identificadores únicos). RES-000087 aparece dos veces, idéntica.
hotel	Texto	Código del hotel de la cadena (H1 a H5)	H1	Solo código: no trae el nombre ni la zona (Centro, Getsemaní, Bocagrande), que deben derivarse en PDI.
tipo_habitacion	Texto	Tipo de habitación reservada	Estándar	12 escrituras para 3 tipos: Estándar, estandar, Standard, STD, Superior, superior, sup., SUP, Suite, suite, ste, SUITE.
fecha_reserva	Texto	Fecha en que se hizo la reserva	18/12/2022	Formato distinto por hotel: dd/mm/aaaa en H1 a H3 y mm-dd-aaaa en H4 y H5 (ej. 04-28-2023).
fecha_entrada	Texto	Fecha de llegada del huésped	01/01/2023	Mismo problema de formato que fecha_reserva.
fecha_salida	Texto	Fecha de salida del huésped	03/01/2023	Mismo problema de formato que fecha_reserva.

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
noches	Entero	Número de noches de la estancia (1, 2, 3, 4, 5 o 7)	2	Sin problemas detectados. Debe coincidir con fecha_salida − fecha_entrada (validar en PDI al unificar fechas).
num_huespedes	Entero	Número de huéspedes de la reserva (1 a 4)	4	2.441 nulos (2.402 sin duplicados).
canal	Texto	Canal de venta (Web directa, OTA, Agencia, Corporativo, Walk-in)	OTA	4.869 nulos (4.804 sin duplicados), ej. RES-000004 (H1). Se cargan como “No informado”.
nacionalidad	Texto	País de nacionalidad del huésped	Colombia	7.330 nulos (7.206 sin duplicados). Nombres oficiales largos (Estados Unidos de América) que difieren de los de otras fuentes.
tarifa_noche	Entero (COP)	Tarifa por noche en pesos colombianos	419000	Con IVA en H4 y H5 (Bocagrande) y sin IVA en H1 a H3, sin columna que lo indique. No son comparables.
tarifa_total	Entero (COP)	Tarifa por noche × noches	838000	Hereda el problema del IVA de tarifa_noche.
estado	Texto	Estado de la reserva (Confirmada o Cancelada)	Confirmada	10.952 canceladas que no ocupan habitación y no deben contarse en la ocupación.

Anexo A.2. Diccionario F1: Migración Colombia (9 CSV, 1.639 filas)

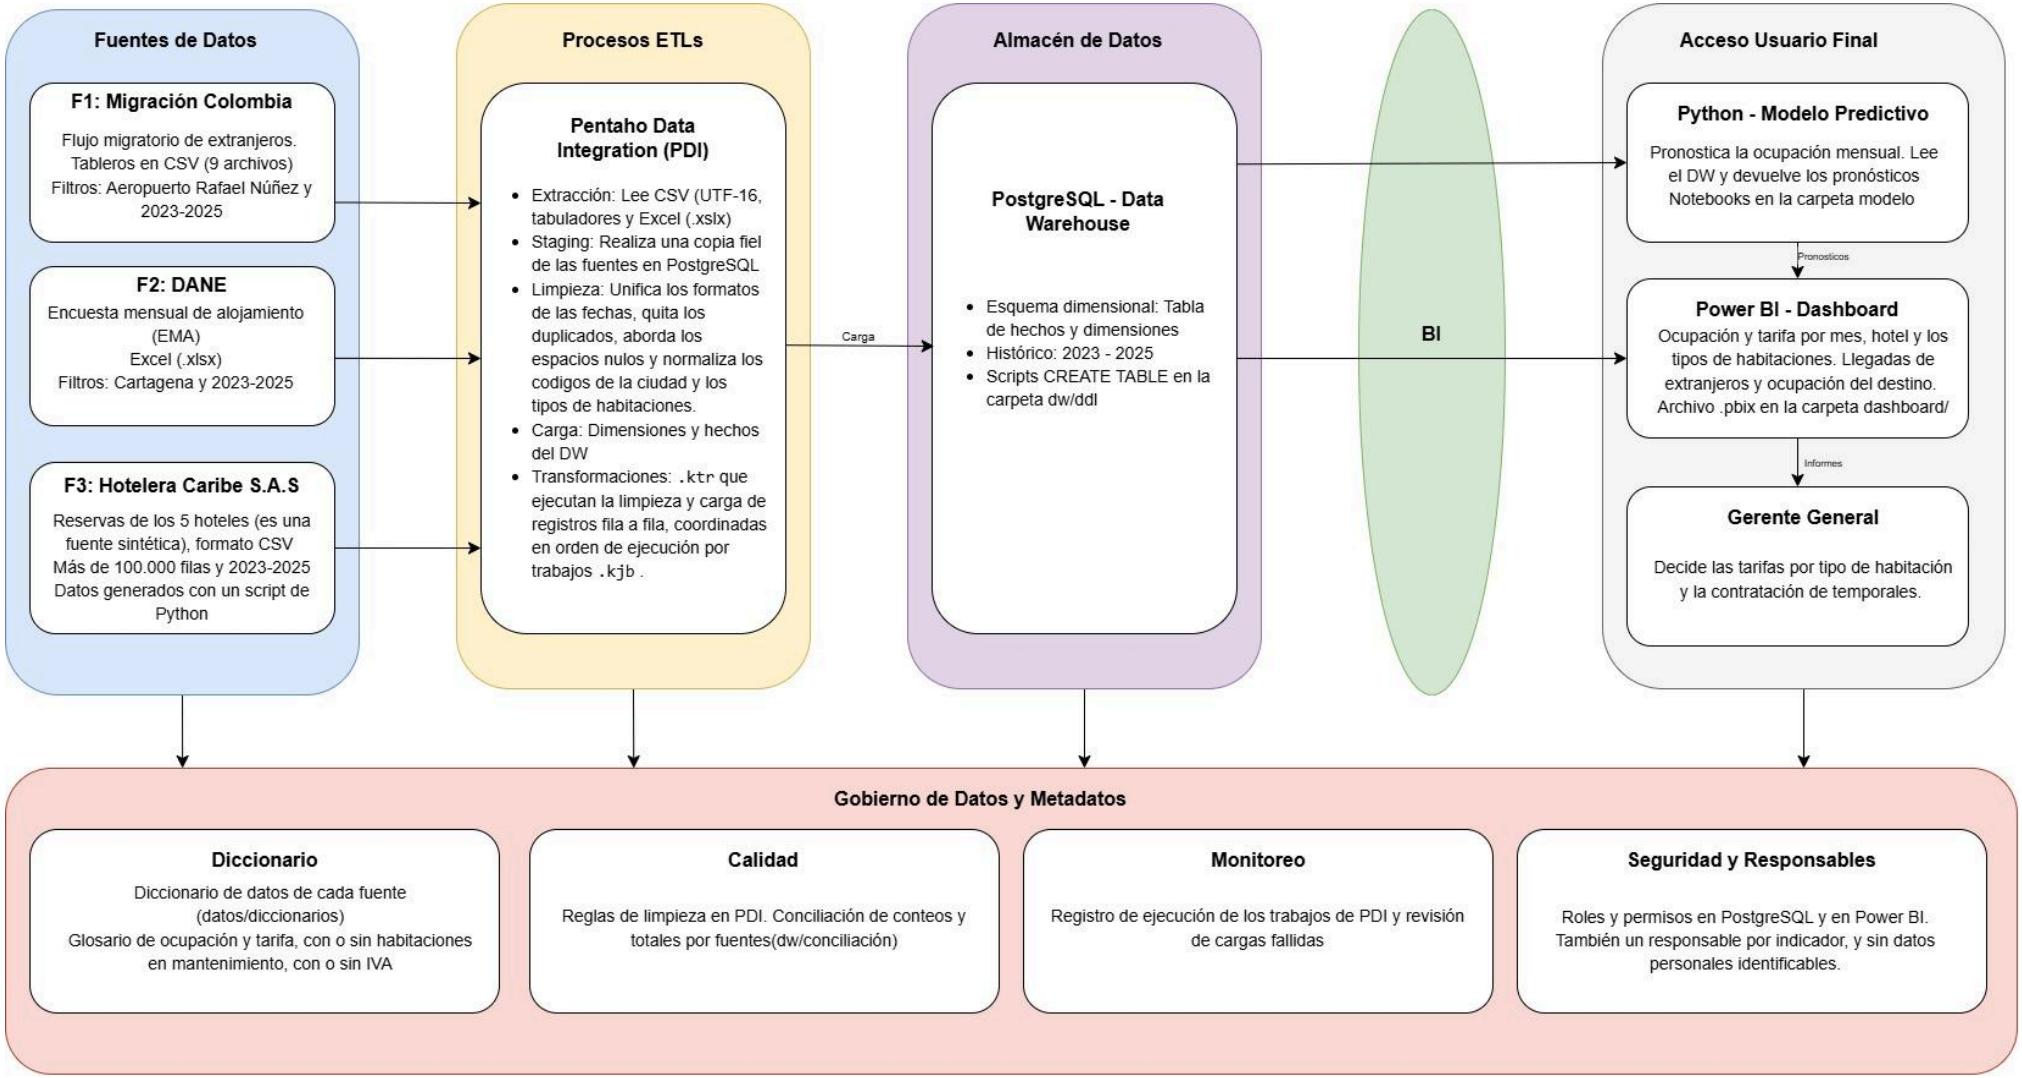
Campo	Tipo	Descripción	Ejemplo	Problema de calidad
Mes (comportamiento mensual)	Texto	Mes del año de las entradas y salidas	Enero	Diseño ancho con dos filas de encabezado: cada mes aparece dos veces (Enero, Enero) con las columnas Entradas y Salidas.
País de nacionalidad	Texto	Nacionalidad del extranjero	Venezuela (República Bolivariana de)	Nombres oficiales largos que no coinciden con los de F3 (Estados Unidos de América).
Color país (auxiliar de Tableau)	Texto	Columna de formato del tablero, sin valor de negocio	Menos de 1.000	Columna auxiliar que debe excluirse en PDI.
Ciudad de hospedaje	Texto	Ciudad donde se hospeda el extranjero	Cartagena de Indias	Solo nombre, sin código de municipio. Hay nombres parecidos (Cartagena del Chairá) y comas dentro del nombre (Bogotá, D.C.).

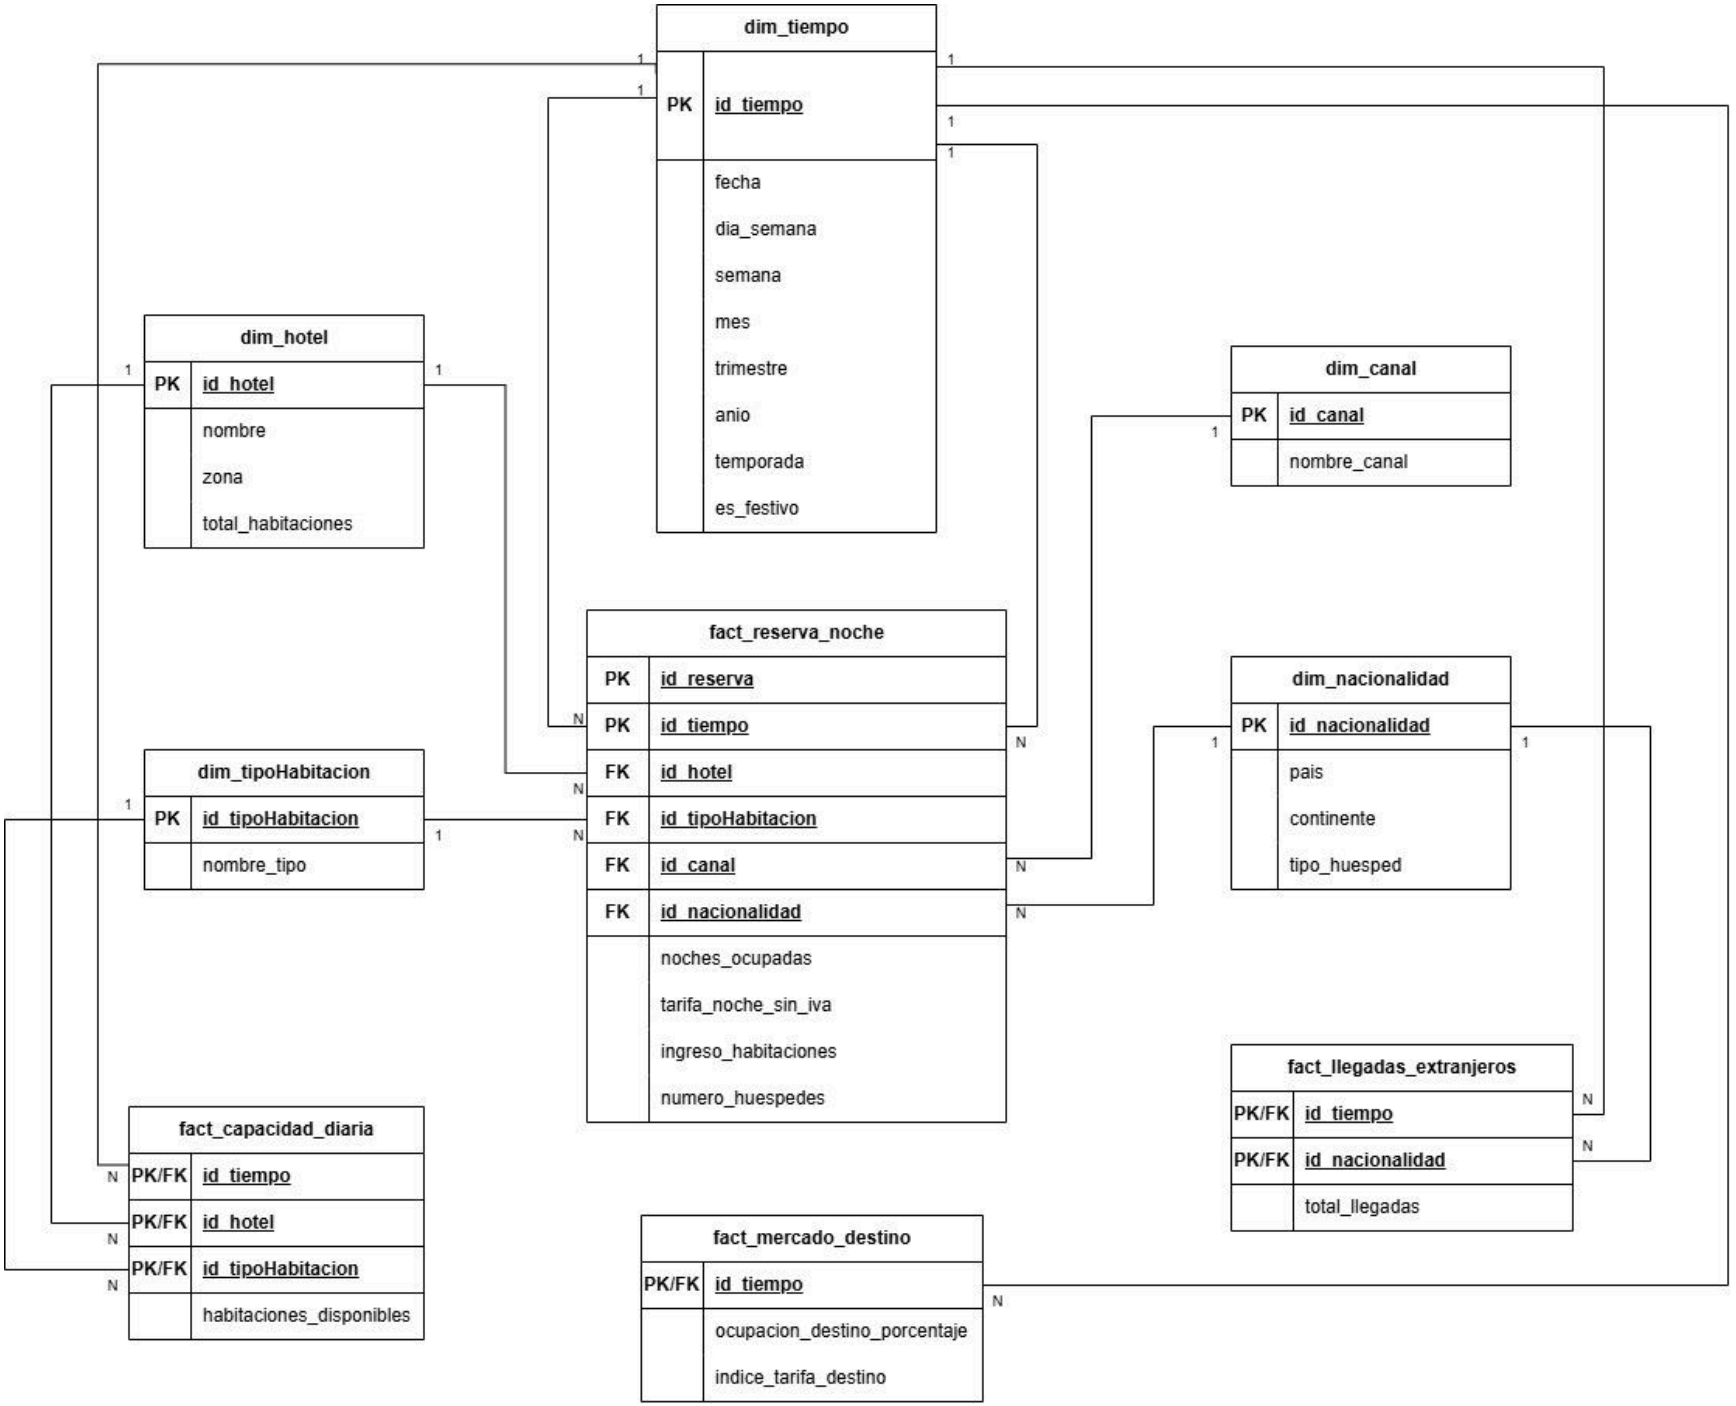
Campo	Tipo	Descripción	Ejemplo	Problema de calidad
Total	Entero (guardado como texto)	Total de extranjeros por país o ciudad	619.405	Separador de miles distinto entre años (2023: 481,626; 2025: 619.405).

Anexo A.3. Diccionario F2: DANE, Encuesta Mensual de Alojamiento (Excel, 36 registros mensuales)

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
Año	Entero	Año del dato	2024	Solo aparece en la primera fila de cada año (enero); de febrero a diciembre la celda está vacía.
Mes	Texto	Mes del dato	Enero	Debe convertirse a número de mes para armar la fecha.
Región o ciudad (columnas: Caribe, Eje Cafetero, Cartagena, …)	Texto (encabezado)	Cada columna es una región o ciudad del dato	Caribe	Espacios sobrantes y saltos de línea en los nombres: 'Caribe ', ' Eje Cafetero', 'Golfo de Morrosquillo \ny Sabana'.
Ocupación (hoja 4.2)	Decimal (%)	Porcentaje de ocupación mensual de Cartagena, en escala de 0 a 100	75.9974596289046 (enero 2023)	Hasta 14 decimales. Hay celdas con "-" cuando no hay dato (5 en la hoja). La unidad es distinta de las demás hojas.
Índice de tarifa sencilla / doble (hoja 6.1)	Decimal (índice)	Índice de tarifa de Cartagena por tipo de acomodación, con base 2019 = 100	149.502069595196 (sencilla, enero 2023)	No es un valor en pesos y no es comparable con la tarifa de F3. Encabezado en tres filas (región, tipo de acomodación, medida) repetido por cada región.
Variación anual de tarifa (hoja 6.1)	Decimal (%)	Variación porcentual anual del índice de tarifa	31.2533426174553 (sencilla, enero 2023)	Celdas con un espacio " " en lugar de dato (todo 2019, que no tiene año previo).
Variación anual de ingresos reales (hoja 1.1)	Decimal (%)	Variación porcentual anual de los ingresos reales de Cartagena (serie desde enero 2020)	15.0434433434097 (enero 2023)	Valores atípicos por la pandemia (5550.78549842111 en abril 2021). Celdas con "-" y "*" en lugar de dato. Otra unidad y otro periodo de referencia.
Notas al pie	Texto	Texto explicativo después del último mes	Actualizado el 13 de febrero de 2026	Filas de texto (Fuente: DANE, EMA; p: Cifra provisional) mezcladas con los datos, que deben descartarse.

Anexo B. Diagramas a tamaño completo


Fuentes de Datos
F1: Migración Colombia
Flujo migratorio de extranjeros.
Tableros en CSV (9 archivos)
Filtros: Aeropuerto Rafael Núñez y 2023-2025
F2: DANE
Encuesta mensual de alojamiento (EMA)
Excel (.xlsx)
Filtros: Cartagena y 2023-2025
F3: Hotelera Caribe S.A.S
Reservas de los 5 hoteles (es una fuente sintética), formato CSV
Más de 100.000 filas y 2023-2025
Datos generados con un script de Python
Procesos ETLs
Pentaho Data Integration (PDI)
Extracción: Lee CSV (UTF-16, tabuladores y Excel (.xslx)
Staging: Realiza una copia fiel de las fuentes en PostgreSQL
Limpieza: Unifica los formatos de las fechas, quita los duplicados, aborda los espacios nulos y normaliza los codigos de la ciudad y los tipos de habitaciones.
Carga: Dimensiones y hechos del DW
Transformaciones: .ktr que ejecutan la limpieza y carga de registros fila a fila, coordinadas en orden de ejecución por trabajos .kjb .
Carga
Almacén de Datos
PostgreSQL - Data Warehouse
Esquema dimensional: Tabla de hechos y dimensiones
Histórico: 2023 - 2025
Scripts CREATE TABLE en la carpeta dw/ddl
BI
Acceso Usuario Final
Python - Modelo Predictivo
Pronostica la ocupación mensual. Lee el DW y devuelve los pronósticos
Notebooks en la carpeta modelo
Pronosticos
Power BI - Dashboard
Ocupación y tarifa por mes, hotel y los tipos de habitaciones. Llegadas de extranjeros y ocupación del destino.
Archivo .pbix en la carpeta dashboard/
Informes
Gerente General
Decide las tarifas por tipo de habitación y la contratación de temporales.
Gobierno de Datos y Metadatos
Diccionario
Diccionario de datos de cada fuente (datos/diccionarios)
Glosario de ocupación y tarifa, con o sin habitaciones en mantenimiento, con o sin IVA
Calidad
Reglas de limpieza en PDI. Conciliación de conteos y totales por fuentes(dw/conciliación)
Monitoreo
Registro de ejecución de los trabajos de PDI y revisión de cargas fallidas
Seguridad y Responsables
Roles y permisos en PostgreSQL y en Power BI.
También un responsable por indicador, y sin datos personales identificables.


dim_tiempo
PK id_tiempo
fecha
dia_semana
semana
mes
trimestre
anio
temporada
es_festivo
dim_hotel
PK id_hotel
nombre
zona
total_habitaciones
dim_canal
PK id_canal
nombre_canal
fact_reserva_noche
PK id_reserva
PK id_tiempo
FK id_hotel
FK id_tipoHabitacion
FK id_canal
FK id_nacionalidad
noches_ocupadas
tarifa_noche_sin_iva
ingreso_habitaciones
numero_huespedes
dim_nacionalidad
PK id_nacionalidad
pais
continente
tipo_huesped
dim_tipoHabitacion
PK id_tipoHabitacion
nombre_tipo
fact_capacidad_diaria
PK/FK id_tiempo
PK/FK id_hotel
PK/FK id_tipoHabitacion
habitaciones_disponibles
fact_llegadas_extranjeros
PK/FK id_tiempo
PK/FK id_nacionalidad
total_llegadas
fact_mercado_destino
PK/FK id_tiempo
ocupacion_destino_porcentaje
indice_tarifa_destino