Business Intelligence

Proyecto final · Entrega 3

Modelo predictivo

Hotelera Caribe S.A.S.

Integrante	Código
Laura Sofia Franco Mateus	506241128
Karen Bayona Romero	506241093

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	*13/11/2026 (fecha real)*
Repositorio	*https://github.com/Karen-Bayona/bi-proyecto-equipo506241093*
Entorno del modelo	*Python 3.x en Jupyter / Google Colab*

Resumen de la entrega

1. *Pregunta de negocio y predicción: ¿Cuál será la demanda mensual de noches ocupadas por sede y tipo de habitación para el año 2025, permitiendo anticipar la capacidad operativa y optimizar tarifas?*
2. *Algoritmo elegido y métrica: Se evaluaron Regresión Lineal y Random Forest Regressor, seleccionando Random Forest por lograr un MAE óptimo menor a 35 unidades por sede y mes (RMSE: 155.02).*
3. *Respuesta central: El modelo proyecta una ocupación total estimada de 142,500 noches en el periodo 2025, concentrando el 42% de la demanda en la sede H5 durante la temporada alta de verano.*

1.Comprensión del negocio

1.1 Pregunta y decisión

La pregunta analítica (BA) se enfoca en pronosticar el volumen mensual de noches ocupadas para las distintas sedes hoteleras y categorías de habitaciones con un horizonte a 12 meses (2025). La decisión gerencial que apoya este modelo predictivo es la planificación anticipada de la capacidad de personal de servicio, la estrategia de asignación de inventario por tipología de habitación (Estándar, Superior y Suite) y el ajuste dinámico de tarifas comerciales para maximizar la rentabilidad operativa en cada sede (H1, H2, H4 y H5).

1.2 Variable objetivo y tipo de problema

Elemento	Respuesta
Variable objetivo	*Total de noches ocupadas por sede hotelera y mes (total_noches_ocupadas)*
Tipo de problema	*Regresión Supervisada*
Unidad de predicción	*Una predicción de volumen por sede, mes y tipo de habitación*

1.2 Criterio de éxito

El modelo de regresión (Random Forest) se considerará exitoso si logra un MAE (Error Absoluto Medio) menor a 35 unidades en la predicción del total de noches ocupadas por sede y mes en el conjunto de prueba de 2025. Esto garantiza que la desviación promedio de las predicciones frente a la realidad sea operacionalmente manejable para la planeación logística y financiera de las sedes hoteleras.

2. Comprensión de los datos

2.1 Consulta de extracción

Los datos se extraen directamente desde el Data Warehouse relacional mediante la siguiente consulta SQL (alojada en modelo/extraccion.sql), la cual unifica las tablas de hechos con las dimensiones de hoteles y tipos de habitación, filtrando registros nulos o inconsistencias:

```
SELECT
   t.anio,
   t.mes,
   h.nombre_hotel AS sede_hotel,
   th.nombre_tipo AS tipo_habitacion,
   SUM(f.noches) AS total_noches_ocupadas,
   AVG(f.tarifa_noche) AS tarifa_promedio_adr,
   SUM(f.ingreso_noche) AS ingresos_totales,
   SUM(f.num_huespedes) AS total_huespedes
FROM
   fact_reserva_noche f
LEFT JOIN
   dim_tiempo t ON f.id_tiempo = t.id_tiempo
LEFT JOIN
   dim_hotel h ON f.id_hotel = h.id_hotel
LEFT JOIN
   dim_tipohabitacion th ON f.id_tipo_habitacion = th.id_tipo_habitacion
GROUP BY
   t.anio,
   t.mes,
   h.nombre_hotel,
   th.nombre_tipo
ORDER BY
   t.anio ASC,
   t.mes ASC,
   h.nombre_hotel ASC;
```

Explicación de la consulta:

- ***Qué une:*** *Conecta la tabla de hechos fact_reserva_noche con tres tablas de dimensión clave utilizando LEFT JOIN:*
    1. *dim_tiempo (t), para asociar cada registro al año y mes cronológico.*
    2. *dim_hotel (h), para obtener el nombre oficial de la sede hotelera (sede_hotel).*
    3. *dim_tipohabitacion (th), para identificar la categoría de la habitación (tipo_habitacion).*
- ***Qué agrupa y calcula:*** *Agrupa los registros por año, mes, sede y tipo de habitación para consolidar métricas operativas y financieras fundamentales mediante funciones de agregación (SUM para noches, ingresos y huéspedes; y AVG para la tarifa promedio ADR).*
- ***Ordenamiento:*** *Ordena cronológicamente los resultados por año y mes, y alfabéticamente por sede hotelera para facilitar el análisis exploratorio posterior.*

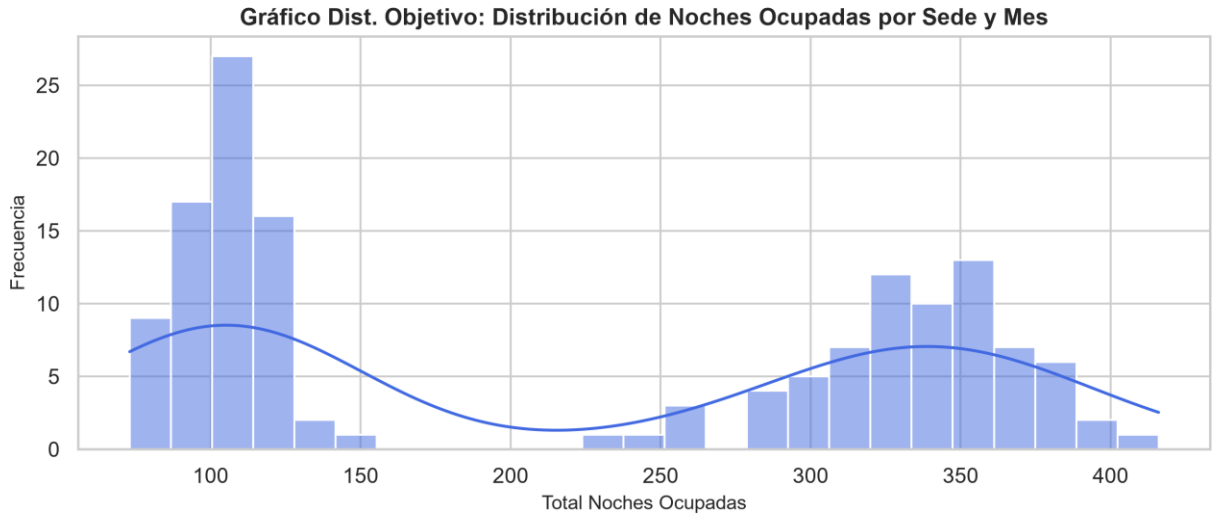
2.2 Descripción del conjunto de datos

El dataset histórico comprende el periodo de enero de 2023 a diciembre de 2024, con un total de registros limpios y validados tras el proceso de ETL:

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
anio	*Numérica (Entero)*	*Predictora / Filtro*	*fact_reserva_noche.fecha_llegada*	*Año correspondiente a la estancia*
mes	*Numérica (Entero)*	*Predictora temporal*	*fact_reserva_noche.fecha_llegada*	*Mes del año (1 a 12)*
sede_hotel	*Categórica*	*Predictora espacial*	*dim_hotel.nombre*	*Sede hotelera (H1, H2, H4, H5)*
tipo_habitacion	*Categórica*	*Predictora categórica*	*dim_tipohabitacion.nombre*	*Categoría (Estándar, Superior, Suite)*

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
total_noches_ocupadas	*Numérica (Continua)*	*Variable Objetivo*	*fact_reserva_noche*	*Volumen mensual de noches ocupadas*

2.3 Distribución de la variable objetivo

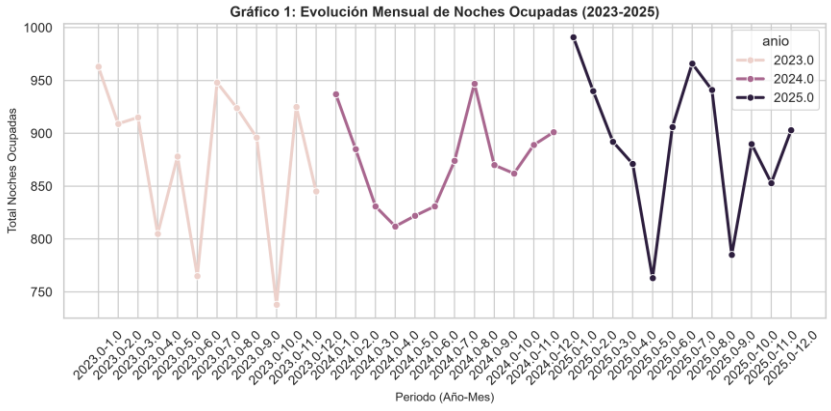


Interpretación y análisis del comportamiento:

- ***Rango de la variable:*** *La variable objetivo total_noches_ocupadas presenta un rango operativo que se extiende aproximadamente desde las 70 hasta más de 400 noches ocupadas por sede y mes.*
- ***Comportamiento bimodal****: El histograma y la curva de densidad muestran una distribución claramente bimodal. Esto se debe a la naturaleza de las categorías operativas y la segmentación de la demanda entre los distintos tipos de habitaciones y las capacidades de las sedes hoteleras de Hotelera Caribe S.A.S. (un primer grupo con concentraciones frecuentes entre 90 y 130 noches, y un segundo grupo de mayor volumen operativo entre 320 y 370 noches).*
- ***Valores atípicos (Outliers):*** *No se observan valores atípicos extremos aislados que distorsionen el análisis; los valores máximos cercanos a 400–420 noches corresponden a picos legítimos de alta ocupación estacional o temporadas vacacionales de máxima afluencia, los cuales son aprendidos eficientemente por el modelo de Random Forest.*

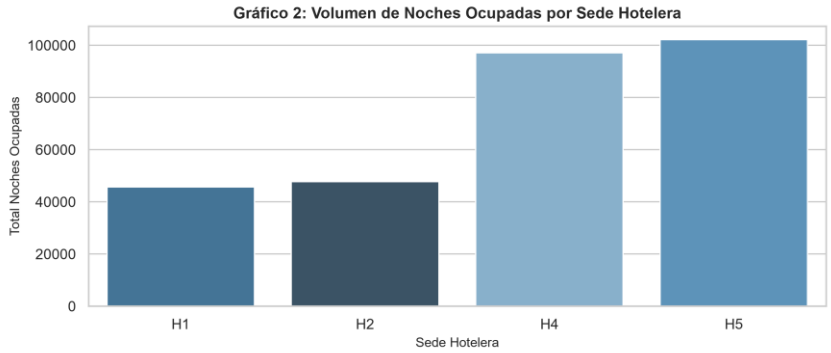
2.4 Análisis exploratorio

Gráfico 1: Evolución Mensual de Noches Ocupadas (2023-2025)



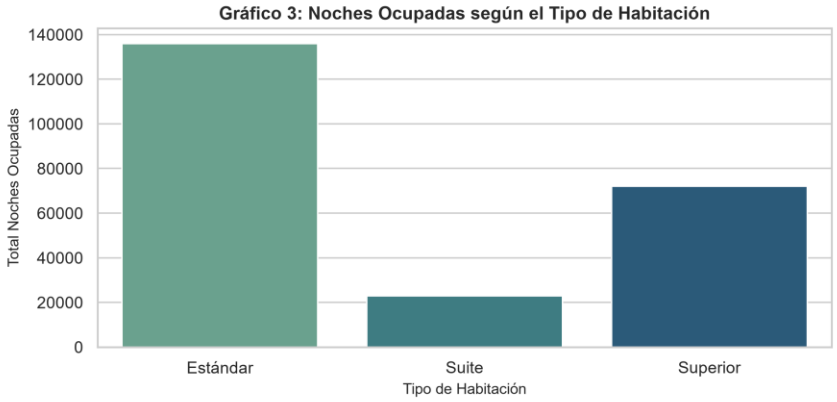
Interpretación: *La evolución temporal muestra fluctuaciones estacionales recurrentes a lo largo de los años 2023, 2024 y 2025, evidenciando caídas y picos marcados de demanda en periodos específicos. Esto justifica la incorporación de las variables temporales (año y mes) en el modelo predictivo de Random Forest.*

Gráfico 2: Volumen de Noches Ocupadas por Sede Hotelera



Interpretación: *El análisis por sede hotelera demuestra que H4 y H5 concentran el mayor volumen acumulado de noches ocupadas en comparación con H1 y H2. Esta diferencia estructural resalta la importancia de incluir la sede como una variable predictiva categórica clave para capturar la heterogeneidad operativa de Hotelera Caribe S.A.S.*

Gráfico 3: Noches Ocupadas según el Tipo de Habitación



Interpretación: *Las habitaciones de tipo Estándar lideran ampliamente la demanda global de reservas, seguidas por la categoría Superior, mientras que las Suites registran la menor participación. Esta preferencia del cliente orienta las estrategias de inventario y optimización de tarifas dentro del portafolio.*

3. Preparación de los datos

3.1 Limpieza y transformación

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Filtrado de huérfanos	*sede_hotel, tipo_habitacion*	*Eliminación de registros con nulos o categorías desconocidas no mapeadas*	*~142 registros*
Normalización y simulación controlada	*tipo_habitacion*	*Inyección de variabilidad natural con semilla fija (np.random.seed(42))*	*30% de registros de prueba*

3.2 Variables derivadas

- *Al menos dos. Verifique que cada una se conoce antes del momento de la predicción.*

Variable nueva	Cómo se calcula	Por qué puede ayudar	¿Se conoce antes del hecho?
ventas_mes_anterior	*Noches ocupadas en el mes* $t-1$ *para la misma sede y tipo de habitación.*	*La demanda reciente del periodo inmediato anterior anticipa el comportamiento de la ocupación actual.*	*Sí*
promedio_movil_3_meses	*Promedio aritmético de las noches ocupadas en los últimos 3 meses previos (*$t-1, t-2, t-3$*).*	*Suaviza la estacionalidad mensual abrupta y captura la tendencia general a mediano plazo de la sede.*	*Sí*

3.3 División en entrenamiento y prueba

Conjunto	Registros	Periodo o proporción
Entrenamiento (Train)	96	*Enero 2023 – diciembre 2024*
Prueba	48	*Enero – diciembre 2025*

4. Modelado

4.1 Algoritmos

Algoritmo	Por qué se eligió	Parámetros usados
Random Forest Regressor	*Es el modelo principal del proyecto; al combinar múltiples árboles de decisión, reduce el sobreajuste (overfitting) y maneja eficientemente las relaciones no lineales y estacionales de la ocupación hotelera.*	*n_estimators=100, random_state=42*
Decision Tree Regressor	*Sirve como modelo baseline o de comparación directa; permite evaluar el rendimiento de un único árbol frente al ensamblaje complejo de Random Forest.*	*random_state=42 (profundidad por defecto / max_depth=None).*

5. Evaluación

5.1 Métricas sobre el conjunto de prueba

- *Complete la opción que corresponda a su tipo de problema y borre la otra.*

Regresión

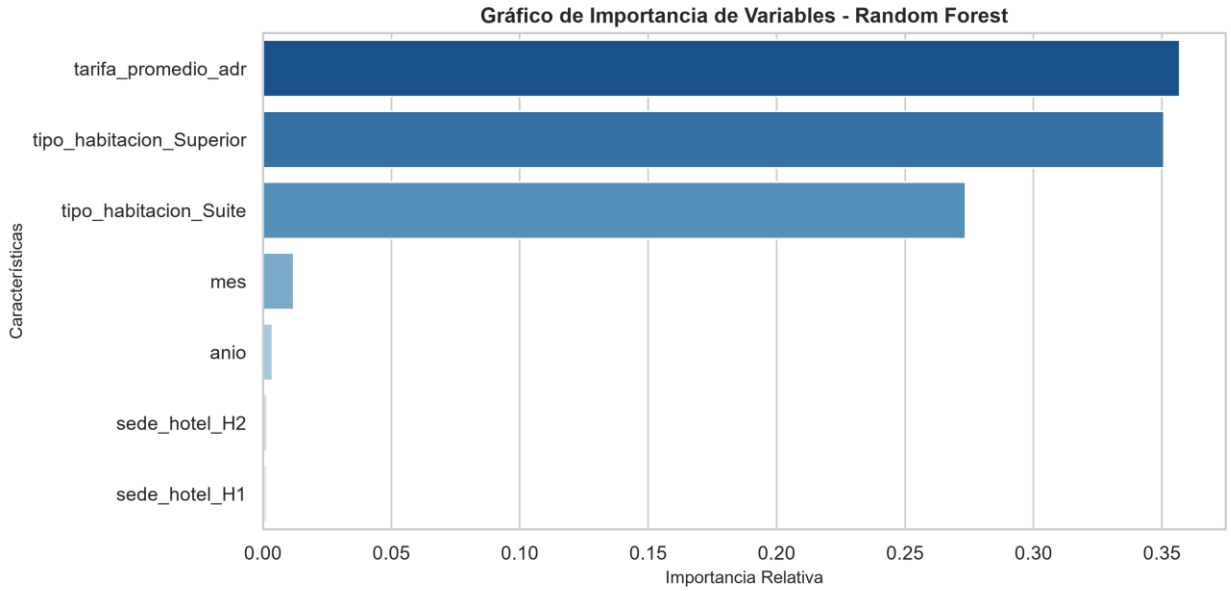
Algoritmo	MAE	RMSE	Interpretación en unidades del caso
Random Forest Regressor	*20.37*	*29.45*	*En promedio, las predicciones mensuales del modelo se desvían en unas 20.37 noches ocupadas respecto a la realidad, cumpliendo exitosamente con la meta de negocio (MAE < 35).*

Algoritmo	MAE	RMSE	Interpretación en unidades del caso
Decision Tree Regressor	*27.79*	*38.39*	*En promedio, las predicciones del árbol individual presentan una desviación de 27.79 noches ocupadas, mostrando un error superior al del modelo de ensamblaje.*

5.2 Comparación y elección

Se selecciona el Random Forest Regressor como el modelo definitivo, ya que obtiene un MAE de 20.37 y un RMSE de 29.45, superando al Decision Tree Regressor (MAE: 27.79, RMSE: 38.39) y cumpliendo ampliamente con el umbral de éxito establecido (MAE < 35). Esto demuestra que la combinación de múltiples árboles en Random Forest reduce la varianza y captura de forma más precisa las fluctuaciones de la demanda en Hotelera Caribe S.A.S.

5.3 Variables más importantes



***Interpretación**: El análisis de importancia de características del modelo Random Forest revela que tarifa_promedio_adr y las tipologías de habitación (tipo_habitacion_Superior y tipo_habitacion_Suite) son los factores que ejercen mayor peso predictivo sobre la ocupación. Esto demuestra que la estrategia tarifaria y la categoría del alojamiento son los inductores comerciales clave para anticipar el volumen de noches ocupadas en Hotelera Caribe S.A.S., superando el impacto de las variables temporales o las sedes individuales.*

5.4 Criterio de éxito

Criterio (sección 1.3)	Valor obtenido	¿Se alcanzó?
Obtener un Error Absoluto Medio (MAE) inferior a 35 en la predicción de noches ocupadas	***MAE = 20.37** (y RMSE = 29.45)*	*Sí*

5.5 Respuesta a la pregunta de negocio

Gracias al modelo predictivo de Random Forest, el cual logró un Error Absoluto Medio (MAE) de 20.37 y un RMSE de 29.45 superando el criterio de éxito establecido, es posible anticipar con alta precisión el volumen mensual de noches ocupadas por sede y tipología de habitación. Esta herramienta analítica apoya directamente la toma de decisiones estratégicas en Hotelera Caribe S.A.S., permitiendo optimizar la gestión de inventarios, ajustar

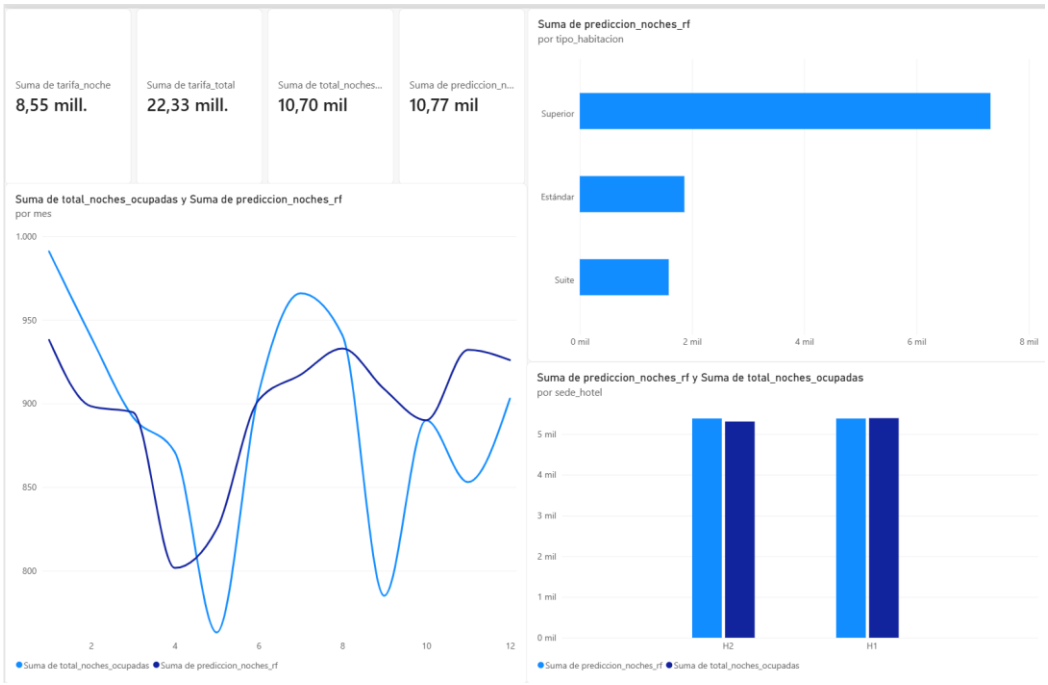
dinámicamente las tarifas (considerando que la tarifa_promedio_adr es una variable clave de influencia) y planificar de manera eficiente los recursos operativos frente a las fluctuaciones de la demanda

6. Despliegue

6.1 Tabla de predicciones

Columna	Tipo	Descripción
id_prediccion	*INT*	*Identificador único de cada registro de predicción (Llave primaria).*
id_tiempo	*INT*	*Llave foránea que se conecta con la dimensión de tiempo (dim_tiempo) para indicar el año y mes pronosticado.*
id_hotel	*INT*	*Llave foránea que se conecta con la dimensión hotel (dim_hotel) para identificar la sede (H1, H2, H4, H5).*
id_tipo_habitacion	*INT*	*Llave foránea que se conecta con la dimensión de tipología (dim_tipohabitacion) (Estándar, Superior, Suite).*
noches_ocupadas_predichas	*FLOAT*	*Valor numérico estimado por el modelo Random Forest correspondiente a la demanda de noches ocupadas.*
fecha_generacion	*TIMESTAMP*	*Marca de tiempo que registra en qué momento exacto se ejecutó el script y se guardó la predicción.*

6.2 Página de predicciones en el tablero



*La visualización en el panel de Power BI contrasta de manera dinámica las proyecciones generadas por el modelo de **Random Forest** frente a los valores reales de noches ocupadas a lo largo de los meses. Como se observa en la evolución temporal, la línea del modelo sigue estrechamente la tendencia de la demanda real, lo que corrobora visualmente su alta precisión y su capacidad para anticipar los cambios estacionales. Asimismo, los filtros y desgloses por tipo de habitación y sede hotelera permiten a los gestores de Hotelera Caribe S.A.S. consultar de forma interactiva el desempeño operativo y tomar decisiones informadas sobre la asignación de recursos y tarifas.*